

3 - 3 - OPTIMERING

Du står på toppen av et fjell $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ gitt ved

$$f(x) = -x_1^2 - x_1x_2 - 2x_2^2 + 4x_1 + 6x_2 + 8.$$

- 1] Hva er koordinatene til toppen? Hvordan vet du at du er på toppen?

En funksjon av to variable har fire andrederiverte. Hvis du partiellderiverer to ganger med hensyn på én variabel, får du de **rene** annenordens partiellderiverte

$$\frac{\partial^2 f}{\partial x_1^2} \quad \text{og} \quad \frac{\partial^2 f}{\partial x_2^2}$$

og deriverer du med hensyn på én variabel og så med hensyn på den andre, får du de **blandede**

$$\frac{\partial^2 f}{\partial x_1 \partial x_2} \quad \text{og} \quad \frac{\partial^2 f}{\partial x_2 \partial x_1}.$$

- 2] Finn de dobbeltderiverte til fjellet f over.

Det er vanlig å sette opp de andreordens deriverte i **hessematrisen**:¹

$$f''(x) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} \end{pmatrix}$$

Denne er som regel symmetrisk, men ikke alltid - se ukens nøtter.

- 3] Finn fram til Taylors andreordens formel for en funksjon fra $f : \mathbb{R}^2 \rightarrow \mathbb{R}$

$$f(x+h) \approx f(x) + f'(x)h + h^T f''(x)h$$

ved å sende en rett linje gjennom x i retning h og bruke kjerneregelen.

I hessematrisen finner vi info om hvorvidt et kritisk punkt er topp eller bunn.


- 4] Forklar hvorfor vi nå trenger å vite om hessematrisen er positivt eller negativt definit eller ingen av delene, og vis at fjellet over har et toppunkt i $(3/7, 1/7)^T$.
- 5] Klassifiser det kritiske punktet til $f(\beta) = (y - X\beta)^T(y - X\beta)$ fra forrige økt.



¹https://en.wikipedia.org/wiki/Hessian_matrix

De kritiske punktene på forrige side er alle enten globale minima eller globale maksima. På gymnaset lærte du at $f : \mathbb{R} \rightarrow \mathbb{R}$ kan ha maksima eller minima i


- kritiske punkter.
- punkter der f eller f' er diskontinuerlig.
- endepunktene i definisjonsmengden.



I flere dimensjoner er det litt mer komplisert, men grunnprinsippene er de samme. La oss introdusere litt notasjon. La Ω være en sammenhengende punktmengde i $\mathbb{R}^2$. Hvis en kurve Γ er randen til Ω , skriver vi

$$\partial\Omega = \Gamma.$$

- 6 Et område $\Omega \in \mathbb{R}^2$ formet ved å ta snittet av første kvadrant med en ellipse med halvaksler 4 og 3, se figur. Du går en skitur på fjellet fra forrige side langs $\partial\Omega$ og ønsker å finne toppunktet på turen. (Du kan for eksempel sette opp parametriseringer for alle de tre bitene av Γ og sjekke.)



De fleste land har sitt høyeste punkt på toppen av et fjell. Men noen land, for eksempel Monaco og Finland, har sitt høyeste punkt i en oppoverbakke et eller annet sted på landegrensen. Kina og Nepal har på en måte begge deler, siden de deler Mount Everest. For funksjoner fra $\Omega \in \mathbb{R}^2$ til $\mathbb{R}$ gjelder det samme - de kan ha maksima og minima inne på Ω eller et eller annet sted på $\partial\Omega$.

- 7 La nå Ω være området på figuren over og f fjellfunksjonen. Hva er $f : \Omega \rightarrow \mathbb{R}$ sitt globale maksimum og minimum?²




²Egentlig må vi nå være nøye på å skille mellom **åpne** og **lukkede** mengder. Mengden Ω er åpen dersom du kan slå en liten sirkelskive rundt hvert punkt i Ω og så er alle punkter i sirkelskiven inneholdt i Ω dersom radien er liten nok. I dette kurset er det nok å forstå den intuitive ideen - Ω er lukket dersom randkurven $\partial\Omega$ er en del av Ω og åpen dersom $\partial\Omega$ ikke er en del av Ω . Slår du en sirkelskive om et punkt på $\partial\Omega$ vil noe av skiven legge seg utenfor Ω uansett hvor liten radien er.

Dersom du skal finne lokale maksima og minima til en deriverbar funksjon må du altså lete på $\partial\Omega$ i tillegg til å lete opp de kritiske punktene til funksjonen. På forrige side parametriserte du antagelig bitene av $\partial\Omega$, men det finnes en annen teknikk som kalles **Lagranges multiplikatormetode**.³ La oss si at du går på fjellet gitt av f og at gps-sporet ditt er gitt av en kurve med likning $g(x) = c$. Figuren under viser trajektorien til en sliten universitetslektor på orrfugljakt. Ekvidistanselinjene på kartet er de brune nivåkurvene til f , og han går en tur gitt av den rosa kurven.

- 8 Forklar ved hjelp av figuren at for det høyeste punktet på turen, bør gradientene til f og g være parallelle, og at dersom nivåkurvene er glatte, finnes det i dette punktet en konstant λ slik at

$$\nabla f(x) = \lambda \nabla g(x).$$



- 9 Hvorfor er dette det samme som å lete etter kritiske punkter til

$$L(x, \lambda) = f(x) + \lambda g(x)?$$

Prøv oppgave 7 på nytt med Lagranges multiplikatormetode.

- 10 Du går på elliptisk skitur på fjellet $h(x) = 1 - x_1^2 - x_1x_2 - x_2^2$, langs trajektorien gitt ved ellipsen med likning $x_1^2 + \frac{x_2^2}{4} = 1$. Finn turens høyeste punkt.

- 11 En ellipse med halvaksler $a = \frac{1}{2}$ og $b = \frac{\sqrt{3}}{2}$, rotert $\pi/4$ radianer i forhold til koordinataksene, tilfredsstiller likningen

$$6(x_1 + x_2)^2 + 2(x_1 - x_2)^2 = 3.$$

Finn den største verdien til $f(x) = x_1 + 2x_2$ på ellipsen.



³https://en.wikipedia.org/wiki/Lagrange_multiplier

Lagranges multiplikator metode dukker opp i et overraskende antall anvendelser. En av de viktigste i dag er kanskje flervariabel regresjon.

- 12 En kjemiker har målt lengden på alle erlenmeyerkolbene på laben. Han har målt lengdene både i tommer og i centimeter og ønsker å sjekke samvariasjonen mellom dem. Men når han prøver å finne den første ordens lineære regresjonen, får han feilmeldingen

`numpy.linalg.LinAlgError: Singular matrix`

når han prøver å løse normallikningene i python. Han er forvirret. Hvorfor skjer dette?

Om datamatriksen X ikke har full rang får man problemer når man skal løse normallikningene. På papiret skjer dette når det er perfekt samvariasjon mellom to variable, men i praksis får man numeriske problemer allerede når samvariasjonen er høy, for da blir kolonnene i X nesten lineært avhengige. Standardmålet på hvor store problemer en matrise har med nesten lineært avhengige kolonner, er **kondisjonstallet**⁴

$$\kappa(A) = \frac{\sigma_1}{\sigma_r}$$

der σ_1 og σ_r er den største og minste singulærverdien.⁵ Problemet med store kondisjonstall, er at *små endringer i matrisen gir store endringer i annet, for eksempel egenverdier*. Dette gjør at modeller kan bli ubrukelige i praksis, siden små målefeil kan gi store endringer i prediksjon.⁶

- 13 I python heter det `np.linalg.cond`. Regn ut kondisjonstallet til

$$\begin{pmatrix} 1 & a \\ b & 1 \end{pmatrix}$$

for forskjellige verdier for a og b . For en illustrasjon av hvordan ting går skeis, kan du prøve å regne ut egenverdier og egenvektorer når $a = 1000$ og $b = 0$ eller $b = .0001$.

Tilnærmet lineær avhengighet mellom kolonnene i X er så og si garantert når det blir mange nok kolonner, og en klassisk teknikk for å håndtere dette kalles **ridgeregresjon**.⁷ Teknikken er enkel å forstå om man har grepet på lagrangemultiplikatorer - du gir opp å lete etter et globalt minimum for $(y - X\beta)^T(y - X\beta)$, og leter heller etter minimum på Ω gitt ved ulikheten $|\beta|^2 \leq r$. Nå ligger det i sakens natur at det globale minimum til $(y - X\beta)^T(y - X\beta)$ ikke skal ligge inne på Ω (i så fall tilfører ridgeregresjon ingenting) så vi leter etter minimum på $|\beta|^2 = r$.

- 14 Hva blir L og hva er minimumspunktet når vi minimerer $(y - X\beta)^T(y - X\beta)$ på $|\beta|^2 = r$?

- 15 På eksamen i TMA4106 i vår fant du det første ordens tovariable regresjonspolynom til punktmengden $(1, 0, 1)$, $(0, 1, 1)$, $(1, 1, 1)$ og $(0, 0, 0)$. Sentrér punktmengden og finn ridgeregresjonen med $r = 1/10$.

⁴https://en.wikipedia.org/wiki/Condition_number

⁵https://en.wikipedia.org/wiki/Singular_value_decomposition

⁶https://en.wikipedia.org/wiki/Butterfly_effect

⁷https://en.wikipedia.org/wiki/Ridge_regression

Når Hoerl og Kennard i 1970 omtaler det at kovariansen “avviker vesentlig fra enhetsmatrisen”, mener de at kovariansen har høyt kondisjonstall.⁸ Enhetsmatrisen er nemlig verdens beste matrise - den har kondisjonstall 1.

16 Vis dette.

Hvis du gjorde nøttene i økt 2-6 i TMA4106, husker du kanskje aksiomene for lengde:⁹

$$1 : |x| > 0 \text{ dersom } x \neq 0$$

$$2 : |ax| = |a||x|$$

$$3 : |x + y| \leq |x| + |y|$$

17 Den euklidske distansen $\|\mathbf{x}\| = \sqrt{\sum_k x_k^2}$ over er et spesialtilfelle av p -normen

$$\|\mathbf{x}\|_p = \sqrt[p]{\sum_k |x_k|^p}.$$

Vis at denne er en lengde og skisser enhetssirkelen i $\mathbb{R}^2$ for forskjellige valg av p .

Fun fact: Fontenen på Sergelplassen i Stockholm har form som enhetssirkelen for $p = 4$.

Velger vi $p = 2$, blir $|A| = \sigma_1$, altså den største singulærverdien.

18 Vis dette og at $\kappa(A) = |A||A^{-1}|$.

En ulempe med ridgeregresjon er at kun unntaksvis setter komponenter i β lik null. **Lassoregresjon**¹⁰ fikser dette ved å bruke 1-normen istedet for 2-normen. Da kan du kvitte deg med overflødige kolonner i datamatriksen.

19 Forklar hvorfor lasso klarer dette, men ikke ridge.

Dette leder oss over på **lineær programmering**.¹¹ Dette betyr bare at kostfunksjonen er $c^T x$ og at Ω er polygonisk. Når $\partial\Omega$ har knekkpunkter, vil man som regel finne maksima og minima på disse. Studass Bjerkehagen laget en gang en hel økt om lineær programmering, og da introduserte han temaet med omtrent denne problemstillingen.

20 Du har snart eksamen i to grusomme fag, og har hundre timer nødpugging igjen til rådighet. Dette koster deg *strev* og *møye*. Det ene faget koster 2.1 *strev* og 2.9 *møye* per time, mens det andre koster 5.0 *strev* og 4.1 *møye* per time. Du tåler 200.0 *strev* og 300.0 *møye* totalt. Skisser Ω .¹²

21 Du scorer 1.0 prosentpoeng på eksamensscore per time lesing i det ene faget og to per time i det andre faget. Finn den optimale balansen.

22 Rasjonelle studenter ønsker å maksimere karakter, ikke poengscore. Hva er den optimale balansen om du ønsker å få best mulig karakter dersom UiOs karakterskala ligger til grunn?¹³ Enn NTNU sin skala?¹⁴

⁸<https://www.jstor.org/stable/1267351>

⁹[https://en.wikipedia.org/wiki/Norm_\(mathematics\)](https://en.wikipedia.org/wiki/Norm_(mathematics))

¹⁰[https://en.wikipedia.org/wiki/Lasso_\(statistics\)](https://en.wikipedia.org/wiki/Lasso_(statistics))

¹¹https://en.wikipedia.org/wiki/Linear_programming

¹²Hva faen er møye egentlig?

¹³<https://www.uio.no/studier/eksamen/karakterer/fagspesifikk-karakterbeskrivelse/mn-math.html#skriftlig>

¹⁴<https://i.ntnu.no/wiki/-/wiki/norsk/prosentvurderingsmetoden>

UKENS NØTTER

Et viktig matrisemåletall er **spektralradien**

$$\rho(A) = \max_k |\lambda_k|.$$

- 1 Vis at dette ikke er en lengde.

For å forklare at hessematrisen gir info om kritiske punkt, er det nyttig å vite at den er symmetrisk. Men det finnes altså patologiske tilfeller der den ikke er det.

- 2 Er hessematrisen til $f(x) = \begin{cases} \frac{x_1 x_2 (x_1^2 - x_2^2)}{x_1^2 + x_2^2} & x \neq 0 \\ 0 & x = 0 \end{cases}$ symmetrisk?

Newtons metode er en teknikk for å løse ikkelineære likningssett, men også en teknikk for å finne kritiske punkter til skalarfelt.¹⁵

- 3 Finn og klassifiser de kritiske punktene til

$$V(x) = x_1^3 + x_1^2 x_2 + x_1 x_2^2 + 2x_2^3 - x_1^2 - x_2^2 - x_1 x_2 - x_1 - x_2.$$

Her kommer en vanskelig en. Vi skal siden se hvorfor den er så vanskelig.

- 4 Finn en harmonisk funksjon med et topp- eller bunnpunkt.



¹⁵https://en.wikipedia.org/wiki/Newton%27s_method_in_optimization